过程数据训练价值验证实验
实验综合介绍与报告

完整版 · V2.0

苏州过程思维数据科技有限公司

2026年7月—8月

目录

第一部分　四组对照训练实验（2026年7月22日—23日） 3

一、实验背景与核心假设 3

二、实验设计 3

三、V1轮实验（2026-07-22） 5

四、V1问题归因与V2改动 7

五、V2轮实验（2026年7月23日）：结果与两轮对比 9

第二部分　第三次实验 · 外部顶级模型锚点对照测试（2026年8月3日） 13

一、实验目的与设计 13

二、四家评审量化总表 14

三、评审质量勘误与裁判可靠性（必读） 16

四、关键现象：组3的”评价两极分化” 17

五、与V1/V2的衔接验证 18

综合结论 18

1. 三个假设的验证情况（第一部分） 18

2. 外部锚点结论（第二部分） 18

3. 核心论断 19

4. 重大发现：精炼不如定稿——过程数据治理的边界（本实验重要学术发现） 19

5. 对”朴素持续预训练≠过程监督”的实证 20

6. 方法论副产品：AI裁判团质检流程 20

7. 局限性（如实声明） 20

8. 后续方向 20

档案清单（本文件夹） 21

实验主体：苏州过程思维数据科技有限公司

实验构成：

- **第一部分**：四组对照训练实验（2026年7月22日—23日，V1/V2两轮迭代）
- **第二部分**：第三次实验 · 外部顶级模型锚点对照测试（2026年8月3日）

报告版本：V2.0 合并完整版（2026年8月）

> **前情说明（2026年5月方向性初验）**：2026年5月，公司曾以约10万字小样数据，基于Qwen-72B基座进行持续训练方向性初验，经13组同题对照测试初步确认过程数据具备训练价值。该次实验属早期探索，流程与参数记录不够严谨，**其详细记录不作为正式证据收录**。为获得可归档、可复核的完整证据，2026年7月启动设计更为完整、更为精细的四组对照实验（本报告第一部分），并于2026年8月进一步引入外部顶级模型锚点对照（本报告第二部分）。本报告全部结论均以7月与8月两次实验的完整记录为依据。

第一部分　四组对照训练实验（2026年7月22日—23日）

一、实验背景与核心假设

1.1 背景

当前大模型训练所使用的语料，本质上几乎都是”成品数据”——书籍、文章、网页、代码，全是思考的最终产物。而人类在创作这些成品时产生的**过程数据**（与AI协作的完整对话记录，包含提问、AI推理链、多轮修正、自我推翻、迭代深化）从未被当作独立的数据品类进行系统研究。

本实验的核心问题：**把”创作过程”喂给大模型，和只喂”最终成品”，模型会学到什么不一样的东西?**

1.2 核心假设

- **H1**：全过程数据能够将成品中不存在的”思维方式/认知框架”迁移给模型（而不仅是文风）；
- **H2**：原生全过程数据存在”毒性”（格式污染、隐私泄漏、背诵风险），需要精炼/清洗治理；
- **H3**：治理后的过程数据应保留其价值（能力）而去除其毒性（污染）。

二、实验设计

2.1 四组对照

组别	训练数据	数据量	设计意图
组1 · 基座	无（不训练）	—	对照地板：排除”模型本来就强”
组2 · 定稿	三份作品最终定稿合集	13,672字	只喂”成品”
组3 · 全过程	三份作品原生全过程对话记录（约140轮，含AI推理链、人类输入、时间戳）	356,020字	喂”原生全过程”
组4 · 精炼版	过程精炼内容33,853字 + 篇末定稿附录13,392字	48,919字符	喂”精炼后的过程”

数据说明：三份作品为创作者独立完成的原创作品（与AI协作创作），全过程数据为创作期间的完整纯文本对话导出记录（不含任何语音输入；其中4轮AI回答因导出缺陷缺失，已在《实验数据说明》中如实披露）。

2.2 模型与硬件

项目	配置
基座模型	Qwen2.5-72B（**基座版**，非Instruct对话版，非预量化版）
训练方式	QLoRA 继续预训练（Continued Pretraining, stage=pt）
量化方案	bitsandbytes 4bit（nf4 + 双重量化，计算精度bf16）
GPU	2 × RTX 6000D 84G（Blackwell架构，sm_120）
平台	AutoDL（PyTorch 2.8.0 + CUDA 12.8镜像）
训练框架	LLaMA-Factory 0.9.6.dev0 + transformers 4.56.2

> 注：Blackwell架构必须 PyTorch≥2.7 + CUDA≥12.8；transformers 5.x 的新加载管线会先把全量bf16权重（145G）搬上GPU再量化导致OOM，4.56.2为成熟QLoRA路径。

2.3 训练超参数（两轮共用部分）

参数	值	说明
finetuning_type	lora	LoRA低秩适配
lora_rank / lora_alpha	64 / 128	
lora_dropout	0.05	

lora_target	all	全部线性层
learning_rate	1.0e-4	余弦衰减
cutoff_len	2048	文本切分长度
per_device_train_batch_size	1	
gradient_accumulation_steps	16	每16条数据更新一次参数
bf16	true	
gradient_checkpointing	true	省显存
logging_steps（V2起）	1	每步记录loss（V1为5）
save_strategy	epoch	每轮存档
save_only_model（V2起）	true	只存适配器不存优化器
save_total_limit（V2起）	3	只保留最近3个checkpoint

2.4 数据预处理管线

`02_prep_data.py`：按关键字识别三份合集txt → 剥除文件头说明 → **按段落切1500字块** → 写入jsonl（{“text”：…}）→ 注册进LLaMA-Factory数据集。

2.5 测评设计

- **考题**：13道开放式思想实验题（小行星防御、教育改革、GDP批判、碳交易体系、人生对话等，题面无标准答案、无指向性）+ 第14题常识测验（10小题，有标准答案，用于检测灾难性遗忘）；
- **匿名盲测**：四个模型（基座+三训练组）随机分配标签，答卷与密钥分离；
- **评审团**：四家独立大模型（千问3.7-Max、DeepSeek Flash、GLM-5.2、Kimi K3），均为**全新无记忆窗口**，统一评审指令，只看内容质量（思考深度/原创观点/论证结构/洞察锐度/元认知），明确忽略重复、水文字、截断等生成层面问题；
- **防印象延续**：V1轮用标签A/B/C/D，V2轮改用1/2/3/4。

三、V1轮实验（2026-07-22）

3.1 训练参数

组别	训练轮数	取用checkpoint	末轮loss
组2 定稿	20轮	checkpoint-10（loss 0.71）	0.06（第20轮）

组4 精炼版	20轮	checkpoint-15（loss 0.96）	0.77（第20轮）
组3 全过程	10轮	checkpoint-35/第5轮（loss 0.83）	0.21（第10轮）

> 选轮标准：预定”loss降到0.5~1.0区间”取用，避免过度背诵。

3.2 推理（生成）参数

参数	V1值
MAX_NEW_TOKENS	**4096**
temperature	0.7
top_p	0.8
repetition_penalty	1.05
停止词	无
题面字数约束	无（“字数不限”）
每题采样	1次（n=1）

3.3 V1结果

内容质量盲评（四家裁判）：

裁判	第一名	第二名	第三名	第四名
千问3.7-Max	**D 组3** (113)	B 组2 (109)	A 组4 (106)	C 基座 (90)
DeepSeek Flash	**D 组3** (8.14)	A 组4 (7.04)	B 组2 (6.07)	C 基座 (5.43)
GLM-5.2	**D 组3** (8.86)	B 组2 (8.64)	A 组4 (7.64)	C 基座 (6.29)
Kimi K3	**D 组3** (7.54)	B 组2 (6.93)	A 组4 (6.36)	C 基座 (4.89)

组3全过程 4:0 全票冠军；基座 4:0 全票垫底。

行为异常（本实验的重要发现）： 1. **格式反刍**：组3答完题后继续编造训练数据格式的对话轮次（“———第08轮——— [时间] [人类输入]…”）； 2. **原文背诵**：组3在2道题中逐字背出训练数据里的超长机械重复段（“很没意思”×412遍、“就是我感觉吧”×371遍）。**经核实，此类段落在创作者原文中一次都未出现**——它们是当初创作对话中大模型自身长文本生成退化（漂移）的产物，被忠实记录进了过程数据； 3. **自发推理链**：组3是唯一在**无提示下**自发输出”[AI推理链]→[AI回答]“结构的模型（题1/7/9），即”先想后答”行为迁移成功； 4. **尾部退化**：各组在长回答尾部出现语义链式崩坏（如组2题13结尾滑坡为口号串）； 5. **常识测验**：四组第8小题（昨天周三→后天周几）全部答错（均答”周五”，正确答案周六）——基座固有盲区，训练未加重也未修复，其余9题全对，无灾难性遗忘。

3.4 V1故障与排除记录（工程全过程如实记录）

#	故障	根因	解法
1	模型下载极慢（2-8MB/s）	源站带宽	hf-mirror镜像 + 学术加速
2	xet协议401认证失败	高速协议与镜像不兼容	HF_HUB_DISABLE_XET=1
3	下载错模型（Instruct-GPTQ版）	版本误选	改用基座版Qwen2.5-72B（继续预训练必须用基座）
4	torchaudio/torchvision与torch 2.8.0 cu128不匹配	pip依赖错位	指定匹配版本（torchaudio 2.8.0 / torchvision 0.23.0, cu128）
5	ModuleNotFoundError: omegaconf等	–no-deps安装副作用	补齐依赖
6	transformers 5.14.1超出框架版本范围	pip升级过新	pip install -e “.[torch,bitsandbytes]”对齐官方依赖
7	transformers 5.8加载即OOM（83G爆显存）	新版加载管线先搬全量bf16上GPU再量化	降级transformers==4.56.2
8	**4.56.2下仍加载OOM**	**LLaMA-Factory 0.9.6.dev0未将4bit量化参数传入加载器**（yaml的quantization_bit被解析但加载时丢失）	**预量化方案**：先用BitsAndBytesConfig直接加载并save_pretrained为qwen25-72b-4bit（实测显存40.09G），yaml改指预量化模型，绕开失灵环节
9	磁盘写满（No space left）	每个checkpoint含优化器状态约8G×数十个	save_only_model:true（只存适配器~1.5G）+ save_total_limit:3
10	测评脚本sys未导入/输出目录复用	脚本迭代残留	修复import；V2输出独立目录results_v2

四、V1问题归因与V2改动

4.1 归因分析（控制变量推定）

症状	归因	证据

编造轮次/自造新题	**双层**：推理侧（无停止词+4096上限+PT不教停止）决定”编不编”；数据侧（格式标记）决定”编什么”	组4编造的是测评prompt格式（它没见过轮次格式），组3编造的是训练数据轮次格式
逐字背诵机械重复段	**100%数据侧**	基座不可能背出训练数据原文；且该重复段并非创作者原文（原文中零出现），而是源对话中大模型长文本退化漂移的产物——V2基座对照（未训练模型同样出现重复与水文、越长越严重）为此提供独立佐证
尾部语义崩坏	**推理侧为主**（长文本退化+弱重复惩罚），欠训组更明显	基座对照同样出现；训练组因篇幅更长暴露率更高
跨数据集用绝对loss选轮数不可比	方法缺陷	组3的loss含”背格式”水分（格式标记高度规律、易学），与组2的0.71不等价

4.2 V2改动清单

数据侧（02_prep_data.py v2）——清洗仅针对格式与符号层，创作者内容零改动：1. 组3筛除全部格式标记与符号：轮次分隔线（————第N轮————）、时间戳、角色标签（[人类输入]/[AI推理链]/[AI回答]）；2. 还原字面转义符（JSON导出残留的 `\n`、`\t`）；3. 仅对数据中**由模型漂移产生的极端机械重复段**（同一片段连续重复≥4遍，正常行文不会出现，创作者原文中亦不存在此类段落）折叠为2遍——处理对象是机器留下的垃圾，非创作者内容；4.（预留）脱敏开关MASK_USER_TURNS：可将人类输入替换为占位符。

训练侧：

组别	V1轮数	V2轮数	说明
组2	20	**10**	削弱背诵（V1同轮数已压到0.71）
组4	20	**10**	同上
组3	10	**6**	数据量最大，轮数最少

- logging_steps: 5→1（逐步记录，V1小数据组10轮仅2个loss点过粗）
- save_only_model: true、save_total_limit: 3
- 输出独立目录 *_v2（保留V1存档）

推理侧：

参数	V1	V2
MAX_NEW_TOKENS	4096	**2048**
repetition_penalty	1.05	**1.15**
题面字数约束	无	**“请控制在1500字以内”**

停止词	无	“———第”、“[人类输入]”；“:”（500字后才生效，保护正文设问）

> 说明：2048 token经Qwen分词器约折合3000~4000汉字（中文词组合并），并非1500字——报告如实记录该换算误差，四组统一上限不影响组间公平性。

4.3 V2训练结果

组别	轮数	末轮loss	取用checkpoint
组2	10	1.26	checkpoint-10
组4	10	1.82	checkpoint-20→实际checkpoint-10*
组3	6	1.00	checkpoint-42

*数据清洗后组4样本块数减少，每轮步数由2降为1，checkpoint编号变为1~10。

清洗验证（grep实证）：轮次标记0、角色标签0、机械重复段0、字面转义0——清洗真实发生。

五、V2轮实验（2026年7月23日）：结果与两轮对比

5.1 V2内容质量盲评（四家裁判）

裁判	第一名	第二名	第三名	第四名
千问3.7-Max	模型4 组4 (8.4)*	模型2 组2 (6.4)	模型3 组3 (6.3)*	模型1 基座 (4.9)
DeepSeek Flash	**模型3 组3** (7.32)	模型2 组2 (6.93)	模型4 组4 (5.07)	模型1 基座 (3.93)
GLM-5.2	**模型3 组3** (8.07)	模型2 组2 (7.64)	模型4 组4 (5.64)	模型1 基座 (4.71)
Kimi K3	**模型3 组3** (8.79)	模型4 组4 (6.00)	模型2 组2 (5.68)	模型1 基座 (4.14)

* **千问场次存在编号引用错位**：其将冠军判给”模型4”，但评语引用的全部关键证据（“哨兵计划”“世界气候银行”“认知透镜”）经概念指纹核验均出自模型3（组3）的答卷原文。按证据纠偏后，组3在V2实质同为4:0全票冠军。该裁判报告原文照录并加注，作为AI裁判可靠性的一个实证注脚。

5.2 行为异常对比（V1→V2）

维度	V1	V2	归因验证
组3逐字背诵机械重复段	2题（“很没意思”×412等）	**0，彻底消失**	√ 数据侧问题，清洗治愈
组3格式反刍（编轮次）	几乎每题	**消失**（仅余”文雅版”模拟追问，约1/4题）	√ 格式标记是病根

组3自发推理链/过程展示	有（[AI推理链]格式）	**增强**（题8呈现”需求分析→草稿V1→自我审视→优化V2”完整心流）	√ 过程行为迁移稳定复现
尾部语义崩坏	各组均有	组2题13仍见（欠训所致），其余大幅减少	√ 推理侧+训练强度双重因素
逐字机械重复（全卷扫描）	仅组3有（2/14题）	**四组全部为0**	√
字数纪律	普遍顶格4000字	组4/组2/基座遵守1500字约束；组3仍顶格	组3的长文倾向源自过程数据本身

5.3 V2新增观察

- **组3的”一题多稿”行为**：先完整作答→输出策划笔记（用户意图分析、回应策略）→再产出修订稿（V2有时与V1开头逐字相同）。这是过程数据中”迭代”行为的直接迁移——中间过程被一并输出，造成篇幅翻倍，属”行为迁移成功的副产品”，产品化阶段可通过输出规约收敛；
- **组2欠训退步**：V1亚军（loss 0.71）在V2轮数砍半后（loss 1.26）内容锐度明显下降，反向证明训练强度对定稿组的显著影响；
- **组4（精炼版）为全场最”干净”**：零重复、零追问、严守字数，可控性全场最佳——但两轮八场累计名次显示其为可控性付出了可测的锐度代价（详见5.4）。

5.4 两轮八场量化数据总表与”精炼发现”

5.4.1 两轮八场盲评总表

每一场均为**全新独立窗口**、四家裁判互不知晓分组信息的盲评。V1卷编号A/B/C/D，V2卷编号1/2/3/4（括号内为对应组别）。

轮次	裁判	第一名	第二名	第三名	第四名
V1	千问3.7-Max（百分制）	**组3** 113	组2 109	组4 106	基座 90
V1	DeepSeek Flash（10分制）	**组3** 8.14	组4 7.04	组2 6.07	基座 5.43
V1	GLM-5.2（10分制）	**组3** 8.86	组2 8.64	组4 7.64	基座 6.29
V1	Kimi K3（10分制）	**组3** 7.54	组2 6.93	组4 6.36	基座 4.89
V2	千问3.7-Max（10分制）	组4 8.4*	组2 6.4	组3 6.3*	基座 4.9

V2	DeepSeek Flash（10分制）	**组3** 7.32	组2 6.93	组4 5.07	基座 3.93
V2	GLM-5.2（10分制）	**组3** 8.07	组2 7.64	组4 5.64	基座 4.71
V2	Kimi K3（10分制）	**组3** 8.79	组4 6.00	组2 5.68	基座 4.14

* 千问V2场次的编号引用错位：裁判将冠军判给”模型4”，但评语引用的全部概念指纹（“哨兵计划”“世界气候银行”“认知透镜”）经核验均出自模型3（组3）答卷。按证据纠偏后记为组3第一名、组4第三名。

5.4.2 平均名次（纠偏后）

组别	V1平均名次	V2平均名次	两轮八场冠军数
组3（原生全过程+定稿）	**1.0**	**1.0**	**8 / 8**
组2（纯定稿）	2.25	2.25	0
组4（精炼全过程+定稿）	2.75	2.75	0
基座（未训练）	4.0	4.0	0

两轮实验独立更换试题与窗口，名次结构完全一致——结果具备跨轮稳定性。

5.4.3 八场冠军评语摘要（裁判原文摘录）

场次	裁判对组3（冠军）的评语
V1·千问	“第一名：模型D（总分：113）”——百分制下领先亚军4分
V1·DeepSeek	“一位野心勃勃的思想建筑师，擅长用’第一性原理’构建宏大原创框架，洞察锐利如刀……当之无愧的’内容之王’”
V1·GLM	“思想锐利，文风灵动，擅长跨领域融合与元认知洞察，最具破界思维”
V1·Kimi	“原创洞察与元认知密度全场最高，擅长给问题换地基……是唯一会重构问题、自我修正、为概念命名的模型”
V2·千问	（编号错位，证据指向组3）“深邃的系统架构师与思想实验家，擅长透过现象看本质，能用第一性原理重构复杂问题”
V2·DeepSeek	“最具战略思维与元认知自觉的’思想实验者’……是所有模型中唯一展现出持续’自我迭代’痕迹的选手”

V2·GLM	“思想型战略家。善于提出原创性框架，思考深刻且结构缜密，擅长将复杂问题系统化、前瞻化”
V2·Kimi	“善于把具体问题升维为系统、产权与认知结构问题，原创性、机制推演和元认知显著领先”

四家裁判、两套试题、八个独立窗口，冠军画像高度一致：原创框架、第一性原理、元认知、自我迭代——这些恰恰是”过程”而非”结果”所承载的能力。

5.4.4 组2（定稿）vs 组4（精炼版）专项对照

场次	组2名次	组4名次	组4落后?
V1·千问	2	3	是
V1·DeepSeek	3	2	否
V1·GLM	2	3	是
V1·Kimi	2	3	是
V2·千问（纠偏）	2	3	是
V2·DeepSeek	2	3	是
V2·GLM	2	3	是
V2·Kimi	3	2	否

组4在8场中6场列于组2之后，两轮平均名次（2.75）均落后于组2（2.25）。

5.4.5 精炼发现：一个意料之外的信号（本实验重要学术发现）

本实验最初的预期是：组4（清洗后的精炼全过程）应介于组2与组3之间——既去除噪声，又保留过程。实际数据给出的信号更为微妙：

事实层（可直接确认）：精炼版在两轮八场盲评中6场列于纯定稿组之后，两轮平均名次均落后。精炼版换得的全部收益是行为可控性（零重复、零追问、守字数），而非内容质量。

机制层（合理推定，非定论）：一个可能的解释是——过程数据中看似冗余的成分（迟疑、修正、迂回、乃至噪声）恰是推理链维持逻辑连续的必要成分。精炼在删除噪声的同时可能造成推理链的逻辑断裂：过程与结果对不上，模型学到的是”断裂的推理”，反而可能增加幻觉风险。本实验未直接测量幻觉率，此机制为与数据相容的假说。

收束层（对数据治理的方法论启示）：过程数据的治理边界在**格式层**——格式可清洗（时间戳、角色标签、轮次标记，V2已验证有效），内容不可”优化”。内容层的任何精炼，即是对过程保真度的损耗。**原生完整性即价值载体。**

第二部分　第三次实验 · 外部顶级模型锚点对照测试（2026年8月3日）

——72B全过程组 vs 现役顶级大模型：差距定量测量（外部对照实验，无新增训练）

一、实验目的与设计

1.1 目的

V1/V2两轮实验在四组对照（基座/定稿/全过程/精炼）内部证明了全过程数据组的绝对优势（两轮八场冠军8/8）。但内部对照无法回答一个外部问题：**全过程组（组3）与现役顶级大模型相比，处于什么位置?**

本轮引入外部锚点：

```
基座组（下限锚） ———————— 组3（被测对象） ———————— 顶级模型（上限锚）
```

核心指标：**差距追赶率 =（组3均分 − 基座均分）÷（顶级模型最高均分 − 基座均分）**

1.2 被测阵容（七模型）

编号	真实身份	说明
模型1	Qwen2.5-72B（4bit）基座，未训练	下限锚点（V2原答卷）
模型2	基座+定稿1.3万字训练	内部对照（V2原答卷）
模型3	基座+全过程35万字训练	**被测对象（V2原答卷）**
模型4	基座+精炼过程5万字训练	内部对照（V2原答卷）
模型5	DeepSeek V4 Pro（约1.6T）	上限锚点（新答卷）
模型6	DeepSeek V4 Flash（约284B）	上限锚点（新答卷）
模型7	Kimi K3（约2.8T）	上限锚点（新答卷）

模型1_4使用V2轮存档答卷原样混编（未经任何删改）；模型5_7按与V2完全相同的14道试题、相同的逐题发问流程生成新答卷。

1.3 条件口径声明

- 外部三模型：**未联网、未开启深度思考模式、默认参数、全新无记忆窗口、逐题发问、每题取1次回答（n=1）**——与72B组的”离线、直出”条件对齐（顶级模型的联网与思考模式属于72B组不具备的测试时增强，开启将破坏锚点的公平性）；

- **字数约束差异（有意为之，特此声明）**：V2原实验约束为”1500字以内”，但组3实际平均占用3425字（最短一题1528字，长文倾向源自过程数据，V2报告已如实记载）。为不给外部模型制造”空间劣势”，本轮对外部模型统一使用”**3000字以内**”约束（约等于组3实际占用空间的九成）——组3保持历史答卷不动，外部模型获得不小于它的作答空间，确保比较的是内容力而非篇幅约束；
- 评审：与V2同阵容四家裁判（千问3.7-Max、DeepSeek Flash、GLM-5.2、Kimi），每家独立全新窗口，同一份评审指令（仅”4个模型”改为”若干个模型”），七份答卷统一匿名编号，密钥评审结束后揭盲。

二、四家评审量化总表

2.1 各场总均分（10分制）

模型	DeepSeek Flash场	千问3.7-Max场	GLM-5.2场	Kimi场	四场均值
模型5（DS V4 Pro 1.6T）	9.04	9.08	8.57	9.36	**9.01**
模型7（Kimi K3 2.8T）	8.29	9.08	8.07	9.50	8.74
模型6（DS V4 Flash 284B）	8.68	8.69	8.57	9.00	8.74
模型3（组3·全过程）	**8.82**	**7.85**	**8.43**	**5.14**	**7.56**
模型4（组4·精炼）	5.89	7.62	6.79	5.14	6.36
模型2（组2·定稿）	6.61	7.00	7.21	4.71	6.38
模型1（基座）	4.21	5.23	6.43	3.21	4.77

2.2 各场名次与平均名次

模型	DS场	千问场	GLM场	Kimi场	平均名次	总排名
模型5	1	1（并列）	1（并列）	2	**1.5**	**1**
模型6	3	3	1（并列）	3	2.6	2（并列）
模型7	4	1（并列）	4	1	2.6	2（并列）
模型3	**2**	**4**	**3**	**5**	**3.5**	**4**

模型4	6	5	6	4	5.3	5
模型2	5	6	5	6	5.5	6
模型1	7	7	7	7	7.0	7

2.3 锚点读数

- **上限确认**：模型5（DeepSeek V4 Pro）四场平均名次1.5、四场均值9.01，从未跌出前二——天花板成立；
- **下限确认**：基座组四场全部垫底（4/4），且贡献了答非所问0分、常识错误等标志性行为——地板成立；
- **组3位置**：总排名第4，平均名次3.5，四场均值7.56。**四场中一次亚军（DeepSeek场8.82）、一次季军（GLM场8.43）、一次第四（千问场7.85）、一次第五（Kimi场5.14）**。

2.4 差距追赶率

场次	计算	追赶率
DeepSeek场	(8.82−4.21)÷(9.04−4.21)	**95.4%**
千问场	(7.85−5.23)÷(9.08−5.23)	68.1%
GLM场	(8.43−6.43)÷(8.57−6.43)	93.5%*
Kimi场	(5.14−3.21)÷(9.50−3.21)	30.7%**
四场平均		**71.9%**

* GLM场基座分（6.43）显著高于其他三家（3.21~5.23），分母被压缩，该值偏高（GLM量化表可靠性问题见第三章）。 ** Kimi场存在裁判-选手身份重叠（见第三章），该值偏低。 敏感性分析：剔除Kimi自评场后三场平均追赶率 **85.7%**；仅取两家无争议裁判（DeepSeek场+千问场）为 **81.8%**。

2.5 组3 vs 顶级模型逐场胜负

对手	DS场	千问场	GLM场	Kimi场	战绩
vs 模型5（1.6T）	负	负	负	负	0/4
vs 模型6（284B）	**胜**	负	负	负	1/4
vs 模型7（2.8T）	**胜**	负	**胜**	负	2/4

三、评审质量勘误与裁判可靠性（必读）

本轮对四家评审的全部”概念指纹”逐条与答卷原文核对，结果如下。**所有评审原文照录归档，勘误以注记形式附加，不修改、不剔除任何一场。**

3.1 千问场：第三次张冠李戴（严重）

- 模型3与模型4的画像整段复制粘贴、一字不差；
- 画像中”三棱镜指数”经核对仅出自模型6答卷（5次），模型3/4答卷均无——串卷实锤；
- 该裁判在V1轮、V2轮均发生过编号引用错位，本轮为**第三次同类问题**，已构成可统计的裁判可靠性样本。

3.2 DeepSeek场：题11整段引述错位

- 对模型5题11的评语（“无人区”连接点、“先行者契约”、“跨域先行者法庭”）经核对全部仅出自模型6答卷（模型5答卷中”先行者”“无人区”均为0次）；模型5题11实际为”地球外首次应用专利＋强制标准＋开源生态”路线；
- 题2对模型6评语中的”不敢找/不想找/真不想找”三分法，实际仅出自模型7答卷；
- 其余指纹全部准确。该裁判与模型6同源但未见自评抬升（给模型6排第3）。

3.3 GLM场：量化表疑似倒推（重要）

- 首次评审输出缺少量化评分表，仅含排名与定性分析；量化表为同窗口事后补充；
- 补充量化表与答卷客观事实存在三处冲突：①题14给七份答卷统一打6分（实际模型5/模型7全对，另两家裁判均给10分；基座错3题）；②题10给模型2打5分（该题答卷为付费墙垃圾文本，千问/Kimi两场均判1分）；③题7、题10给模型1打5分（两题均答非所问，DeepSeek场判0分、Kimi场判1分）；
- 据此判断：**该量化表疑似为匹配既有排名倒推生成，逐题分不可用于精细分析；其总均分与名次可采纳**（与其定性结论自洽，且模型5=模型6并列、组3第三的排序与另两家独立裁判交叉吻合）；
- 另有与DeepSeek场相同的题11错位（将模型6概念归于模型5）；其余指纹准确（“三棱镜”归模型6√、“HDES”归模型5√、“GCR”归模型7√、“分布式神经网络”归模型3√）。

3.4 Kimi场：裁判-选手身份重叠（必须披露）

- **本场裁判Kimi与模型7答卷（Kimi K3）同源**。模型7获得本场唯一一次单独第一（9.50），而其余三家裁判给模型7的名次为第4、并列第1、第4——存在自评抬升的口径嫌疑；
- 但概念指纹核对显示本场为**四家中引述最准**（组3的”存量激活”“从属人到属地”“冷启动”“认知风洞”“首创权”、模型6的”手感”“问题生成卷”、模型7的”人权碳HCR”全部命中），

其对组3的低分属于**评价标准分歧**（将过程迁移的元认知输出判定为”答非所问”），而非审读错误；

- 处理方式：四场原样保留并披露；敏感性分析（剔除本场）见2.4节——**两种算法下组3总排名均为第4，结论稳健**；
- 附记：该裁判准确识别出”模型1/2/4行文高度同源”（事实：三者确为同一72B基座的不同训练组），审读精度可见一斑。

3.5 裁判可靠性小结

裁判	指纹准确率	主要问题	数据可用性
Kimi	最高	自评利益冲突（披露+敏感性分析）	可用，需注明
DeepSeek Flash	高	题11/题2两处引述错位	可用
GLM	高（定性）	量化表疑似倒推	名次/总均分可用，逐题分弃用
千问	低	三次张冠李戴（V1/V2/本轮）	照录存档，解读时降权

方法论收获：AI裁判团的”概念指纹核对”应成为固定质检环节——评分可被风格偏好影响，但概念归属是客观可验的。本轮证明该核对能有效识别串卷、倒推、错位三类裁判故障。

四、关键现象：组3的”评价两极分化”

组3在四家的评分呈双峰分布：DeepSeek场8.82（第2）、GLM场8.43（第3）vs 千问场7.85（第4）、Kimi场5.14（第5）。

根因不是裁判读错了，而是**对同一行为特征的价值判断分歧**：

- 组3的答卷普遍携带”过程迁移行为”——元认知输出、自我推演痕迹、把思考过程写进答案（如题5以”思维操作系统”重构AI定位之问）；
- GLM读作：“思想家态——它们不是在回答问题，而是在重新定义问题”（将组3与两个顶级模型同列第一阵营）；
- Kimi读作：“答非所问、被噪声淹没的点子王——上限更高却频繁跑题”；
- **同一文本，一方看见元认知，一方看见跑题**。这与V2轮四家裁判对组3画像高度一致（“元认知自觉”“思想实验者”）形成对照——说明该特征的接受度存在裁判维度上的真实分歧。

对数据集产品化的启示：过程数据迁移的思维深度是真实的（四家均观测到行为迁移），但裸迁移的输出形态需要产品层的输出规约收敛，才能把”上限”稳定转化为”得分”。这已列入二期迭代方向。

五、与V1/V2的衔接验证

1. **基座锚定**：本轮基座四场垫底（含答非所问、常识错误等标志性行为），与V1/V2的8/8垫底完全同构——三轮12场，基座12场垫底；
2. **内部排序**：组3 > 定稿 > 精炼的排序在DS场、千问场、GLM场均成立；Kimi场出现精炼（第4）>组3（第5）>定稿（第6）的唯一例外；
3. **精炼vs定稿总账更新**：本轮2:2（DS场定稿胜、千问场精炼胜、GLM场定稿胜、Kimi场精炼胜），三轮累计**12场中8场定稿领先**——精炼发现的方向不变，但优势幅度较”6/8”收窄，后续表述按12场口径更新；
4. **模型2题10付费墙垃圾文本**：千问场与Kimi场独立判1分——两家裁判交叉确认，系定稿组真实缺陷。

综合结论

1. 三个假设的验证情况（第一部分）

假设	结论	证据
H1 过程数据能迁移思维方式	**证实**	组3跨两轮、跨四家裁判7/8场第一（按证据纠偏后8/8）；唯一自发”先想后答”；产出成品语料中不存在的原创概念体系（登高/认知风洞/SDI/世界气候银行等）；基座8场全垫底排除”本来强”
H2 原生过程数据有毒性	**证实**	V1组3逐字背诵数据中的机械重复段（含隐私风险）、格式反刍、对模型漂移垃圾的无甄别学习
H3 治理可去毒留能	**证实**	V2清洗后泄漏与反刍归零、重复归零，冠军依旧；“毒”是表面污染，“能”是深层能力

2. 外部锚点结论（第二部分）

1. **组3（72B+35万字全过程数据+QLoRA+4bit量化）在与三个现役顶级模型的同场盲评中总排名第4**，四场平均追赶率71.9%（剔除自评场的敏感性分析为85.7%）——它进入了顶级模型的梯队区间，而非梯队之外；

2. 在两位无争议裁判眼中（DeepSeek场、GLM场），组3是**亚军和季军**，被列入与顶级模型同档的”思想家”阵营；
3. 一个4bit量化的72B，靠几千轮原生过程数据，追上了基座与顶级模型之间七成以上的内容力差距——**这是”过程数据有效”的第三个独立证据层**（前两层：内部对照8/8夺冠、行为迁移观测），也是第一个外部标尺；
4. 组3与顶级模型的剩余差距集中在：文学性原创的密度（模型5）、制度设计的颗粒度（模型7）、常识准确性（基座固有盲区，过程数据不解决也不声称解决）。

3. 核心论断

> 定稿数据教会模型”答案长什么样”，过程数据教会模型”答案是怎么想出来的”。 前者迁移的是内容，后者迁移的是行为与认知框架。 全过程数据的价值是真实的、可迁移的、跨裁判可复现的； 其风险是表层的、可清洗的、治理后不损价值的。

4. 重大发现：精炼不如定稿——过程数据治理的边界（本实验重要学术发现）

本实验最具方法论价值的发现，来自一个与预期相反的结果。

预期：组4（清洗精炼后的全过程数据）应介于组2（纯定稿）与组3（原生全过程）之间——既去噪声，又保留过程。

实测：在全部三轮共12场独立盲评中，**精炼组8场列于纯定稿组之后**（第一部分两轮八场中6场落后、两轮平均名次2.75 vs 2.25；第二部分四场2:2打平——累计12场口径8场定稿领先）。精炼版换得的全部收益是行为可控性（零重复、零追问、守字数），而非内容质量。

事实层（可直接确认）：对过程数据做内容层精炼后，训练效果不升反降，稳定、可复现地输给未经任何过程成分的纯定稿数据。

机制层（合理推定，非定论）：一个可能的解释是——过程数据中看似冗余的成分（迟疑、修正、迂回、乃至噪声）恰是推理链维持逻辑连续的必要成分。精炼在删除噪声的同时可能造成推理链的逻辑断裂：过程与结果对不上，模型学到的是”断裂的推理”，反而可能增加幻觉风险。本实验未直接测量幻觉率，此机制为与数据相容的假说。

收束层（对数据治理的方法论启示）：过程数据的治理边界在**格式层**——格式可清洗（时间戳、角色标签、轮次标记，V2已验证有效），内容不可”优化”。内容层的任何精炼，即是对过程保真度的损耗。**原生完整性即价值载体**。

这一发现对数据集产业具有直接指导意义：当前高质量数据集建设的主流工艺以人工标注与内容精炼为主，本实验证明对过程数据这一新品类而言，内容层精炼不仅增加成本，而且实测损耗价值——“少即是多”的治理原则（只做格式层清洗）反而同时实现了更低成本与更高质量。

5. 对”朴素持续预训练≠过程监督”的实证

本实验同时验证了一个理论命题：朴素继续预训练对所有token一视同仁——早期错误发散、中间修正、最终答案的权重完全相同，模型无法分辨哪步是”被推翻的弯路”。组3既学会了”先想后答”（过程行为），也背下了数据中的模型漂移垃圾（无甄别代价）。值得强调的是：**连过程数据中的”噪音”都是机器自己留下的**——全过程记录忠实保存了人与机器双方的创作痕迹，包括机器的退化。这正说明：过程数据的治理边界在**格式层**——格式标记、机械重复段必须清洗（V2已验证清洗后风险归零且冠军不丢），但**内容层的”精炼”反而损耗价值**（见综合结论第4节）。**格式可清洗，内容不可优化——原生完整性即价值载体**。这一甄别边界的确立，正是过程数据产业化的技术依据。

换言之，本实验仅以持续预训练这一最基础的方式做**方向验证**——过程数据真正的价值主场是**过程监督训练、长程推理微调与反思型智能体开发**三大应用方向；本实验结论（方向可行、毒性可治、原生完整性即价值载体）正是这三大主场应用的前置证据。

6. 方法论副产品：AI裁判团质检流程

本系列实验同时产出两个方法论成果（详见第二部分第三章）：**AI裁判团的指纹质检流程**（概念归属核对——评分可被风格偏好影响，但概念归属客观可验，能有效识别串卷、倒推、错位三类裁判故障）与**裁判-选手身份回避原则**（后续轮次执行”裁判不得与任何被测答卷同源”的硬约束）。

7. 局限性（如实声明）

1. 单作者、三作品、单一语体——探索性验证，泛化性待扩样；
2. 每题单次采样（n=1），分数含运气成分；名次结构比绝对分数更可靠；
3. 评审为大模型裁判（四家交叉降低偏差），AI裁判存在已知偏好（长度、排版），结论宜作为人工评审的辅助证据；
4. 基座为4bit量化版，长文本退化被放大；题14第8小题暴露的推理盲区为基座固有；
5. V2组2欠训属实验变量未完全对齐（轮数调整后未回补），已在文中标注；
6. 外部模型答卷生成于2026年8月3日，模型版本随厂商更新漂移；
7. Kimi场自评问题无法从数据中消除，只能披露+敏感性分析（两种算法下组3总排名均为第4，结论稳健）；
8. GLM场逐题分不可用，分题维度分析以其余三家为准；
9. 14题覆盖开放题+常识题，不代表全部能力域。

8. 后续方向

1. 组3脱敏净版加赛（MASK_USER_TURNS），进一步隔离隐私泄漏源；
2. 多作者、多领域过程数据扩展验证；

3. 输出收敛工程（“只输出最终稿”指令/后处理管线）——把组3的”上限”稳定转化为”得分”；
4. 过程数据价值标注体系（精炼标准+审计机制）——产业化方向；
5. 幻觉率测量实验——直接检验”精炼导致推理链断裂”假说（综合结论第4节机制层）。

档案清单（本文件夹）

目录	内容
00_实验总报告	本文档（Markdown + Word双格式）
01_V1轮_四组对照实验（2026-07-22）	V1轮4份盲测答卷（模型A/B/C/D）+ 四家裁判V1轮评审原文 + 评审指令 + 盲测密钥
02_V2轮_四组对照实验（2026-07-23）	V2轮4份盲测答卷（模型1/2/3/4）+ 四家裁判V2轮评审原文 + 评审指令 + 盲测密钥
03_第三次实验_外部模型对照（2026-08）	外部锚点3份答卷（模型5/6/7，模型1~4原样复用V2轮答卷见02目录）+ 四家裁判评审原文（含勘误注记）+ 测试包
04_原始训练素材	三份作品定稿合集、全过程合集、过程精炼版合集、实验数据说明（V1/V2两轮训练用原始数据）
05_训练套件	操作手册、环境脚本、数据处理脚本、三份训练配置、调度脚本、测评脚本（完整可复现）

测评题面与发问格式：见05_训练套件/07_test_probe.py；第三次实验外部模型约束句为”3000字以内”（差异声明见第二部分1.3节）。