数据资产档案 · 附件 4

治理工程实施档案

人机协同创作长程推理链数据集

新型数据品类的生产、治理、验证与合规资产化实践

主体：皇清华（苏州过程思维数据科技有限公司）

2026年10月

核心成果与现行口径

本册记录主数据集从原始会话导出到可登记、可复核数据资产的治理过程。前置部分只采用**477窗现行口径**；实施期形成的485窗历史数字保留在后面原始档案及口径变迁记录中。

现行治理成果

项目	结果
来源与规模	477窗＝DeepSeek 454窗＋Kimi 23窗；2026-02-24至2026-06-14，共110天
消息与轮次	38,336条消息；18,744轮；三元组18,143组（96.8%），两元组601组；缺链窗口4个如实标注
文本与成果	全量文本46,155,043字；30份定稿合计296,168字；过程：定稿＝156：1
归属与切割	690个归属－窗配对；42窗切割为198个唯一片段
结构化产物	7张数据表，合计20,599行、86字段；另含过程包、校验记录与MD5清单

合规剔除

原始采集中的豆包平台来源8窗，因登记产权与商用合规整体剔除，**不进行商用**，不进入登记与流通范围。剔除后的全部现行统计均自477个原始JSON重新实计复核。

证据功能分开理解

- **MD5：**用于文件完整性与版本一致性核验。
- **可信时间戳：**用于证明相应电子文件在特定时间已经存在及其后未被篡改。
- **数据知识产权登记证书：**用于登记与权属证据链，不承担文件级完整性技术证明。

> **保真原则：**原始导出缺陷仅作序列化层还原；正文零删改，缺失如实标注。历史脚本、路径与统计数字作为工作现场记录保留，不回改粉饰。

目录与阅读指引

部分	内容	页数	总页码
前置	核心成果、现行口径与目录	3页	1—3
第一部分	实施对象与六步治理管线	5页	4—8
第二部分	校准口径、脚本库、参数与归属实例	5页	9—13
第三部分	校验结论、485→477口径变迁与已知边界	2页	14—15

几分钟阅读路径

1. 先看第2页，掌握现行规模、合规剔除与证据功能。
2. 再看第4—8页，理解采集导出、容错解析、轮次化、归属判定、守恒切割、质检统计如何衔接。
3. 需要核对历史数字时，只进入第14—15页的口径变迁记录，避免把实施期数字当作现行口径。

电子产物如何对应

附件4.1提供7张结构化数据表、过程包和校验指纹。总匹配表用于按窗核查归属，逐轮统计明细用于复算轮次，校验与指纹文件用于检查版本和归档一致性。

> **页眉说明：**每页同时标注总页码与本部分页码；前置导读为新增导航，后续实施档案保留历史原件内容。

治理工程实施档案——人机协同创作长程推理链数据集

> 本档案是《人机协同过程数据治理规范（通用模板）V1.0》的**首次完整实施记录**，对应参数 N=30（30 份定稿作品）。档案保真原则：实施期产生的脚本、规则文档、判定与仲裁记录均为历史原件，一字未改；其中硬编码的目录路径、窗口数量、作品名称为当时工作现场的真实记录，不复改、不粉饰。2026 年 10 月发生的来源剔除（豆包 8 窗）以”口径变迁”一章单独记录，新旧口径并存可各自复算。

记录主体：苏州过程思维数据科技有限公司 治理工程实施日：2026-09-06（终审复核同日完成） 档案整理日：2026 年 10 月

一、实施对象（输入）

项	内容
原始数据	485 个会话窗口 JSON（鲸鱼/DeepSeek 454 窗、KM/Kimi 23 窗、豆包 8 窗），时间跨度 2026-02-24 至 2026-06-14（110 天）
定稿成果	30 份 docx，合计 296,168 字
来源分包	鲸鱼文件包、KM 文件包、豆包文件包（三个平台原生导出包）
工作目录	`/mnt/agents/work/数据整理/`（含 _判定、_复检、_全文、_审核包 子目录）
交付目录	`/mnt/agents/output/数据整理交付/`

二、管线实施实录（对照规范第三章六步）

第①②步　采集导出与容错解析

- 三个平台原生导出；平台原生 JSON 存在序列化缺陷（截断、转义符残留），经容错解析还原为规范 JSON，并渲染全文文本至 `_全文/{窗口 ID:03d}.txt` 供判定通读；
- 纪律：正文零删改，仅还原序列化残留的换行与引号；缺失轮以 answer_missing 如实标注、不补写；
- **如实说明**：容错解析与全文渲染在当时会话环境中逐步完成，未形成独立脚本入档。

第③步　轮次化

- 规则：连续同角色消息并组；一组人类输入＋紧随一组 AI 回复＝1 轮；AI 回复含 thinking 块即三元组；
- 脚本：`逐轮统计脚本.py`（工作文件名 stats_rounds.py），输出 `13_逐轮次统计明细.csv`（19,165 行×10 列，485 口径）；
- 豆包窗说明：豆包导出消息体结构与统计脚本 text 字段口径不匹配，其 421 轮在逐轮统计中**计轮不计字**（字数为 0）——此为后续剔除前后对话口径字数不变的技术原因；
- 思维链含缺由 `stats_cot.py`（未入档，见第四章清单）单独统计，产出 `思维链统计明细.csv`；缺链窗口 12 个（鲸鱼 2＋豆包 8＋KM2，豆包 8 窗系平台导出差异、非数据缺损）。

第④步　归属判定（多方判定与仲裁机制）

按规范第五章闭环执行，实际配置：8 批判定＋8 批复检。

1. **代码初筛**：jieba 分词＋TF-IDF 关键词打分，每窗产出归属候选 1–3（写入总表”初判候选”列；未形成独立脚本入档）；
2. **首轮判定**：8 个判定机器人分 8 批通读全文，按六字段（归属/创作行为/状态/有效片段/置信度/理由）产出；
3. **盲判复检**：8 个复检机器人独立第二意见，不看首轮判定，复检规则见《07_判定规则_三十一三十二类.md》原件；
4. **机器比对**：比对脚本.py（compare.py）逐窗比对，非法归属词校验；
5. **分歧分类**：分歧分类脚本.py（classify_diffs.py）＋C 类细分脚本.py（classify_c.py）——255 窗有分歧：A 类行为翻转 56 窗／B 类仅 F 类差异 54 窗／C 类作品分歧 145 窗（C1 复检扩充 34／C2 作品转 F 类 69／C3 真冲突 15／C4 复检缩减 27）；
6. **人工仲裁**：C3+C4 共 42 窗逐一亲审定锤（采样通读原文、逐窗写仲裁理由）；低置信/待定 24 窗全部亲审；仲裁结论经 writeback_c34.py（未入档）写回 领队亲审 24 窗.json；合计 139 窗经人工裁决/亲审，占 28.7%；
7. **随机抽检**：抽检校准.py（未入档）——随机种子 **20260906** 固定抽取 55 窗（约 1/9）人工核验，53 窗成立；发现”单贴求认证窗”跨批次口径不一致（025/058 仅提及 vs 同型窗实质），按用户校准口径统一翻转 28 窗＋1 窗改归 F31，重跑终表抽检结论落盘 抽检结果.json；
8. **终表汇合**：终表汇合脚本.py（merge_final.py），优先级链：**领队仲裁 JSON ＞ A 类校准（采纳实质方）＞ B 类/C1/C2 采纳复检 ＞ 双判一致保原判**；双判一致但无归属者统一转 F32；机器断言：485 行、窗口 ID 1–485 连续、归属全部合法、无待定/无残留；产出 终版总表_32 类.csv 与 总匹配表_485 窗口_32 类终版.csv。

第⑤步　守恒切割

- 切割窗口清单（44 窗，硬编码于归档与校验脚本）：002, 003, 015, 111, 199, 201, 217, 220, 226, 230, 291, 307, 311, 331, 341, 342, 344, 349, 353, 360, 362, 364, 366, 368, 371, 377, 381, 383, 384, 416, 432, 434, 438, 439, 441, 444, 452, 454, 458, 461, 470, 472, 473, 475；
- 切割规则：《08_截取规则_用户补充.md》原件——话题转折点粗切、切口前后各留 3 条缓冲、片段头部溯源注释（源窗口 ID/原文件名/截取范围/切割依据）、碎段（<8 条）并入相邻段取归属并集；
- 切割执行：按规则人工执行＋脚本校验（切割执行本身无独立脚本入档）；
- 结果：214 个唯一片段；因多归属复制产生片段副本 54 份，落盘片段文件合计 268 份；分组：002–291 系 11 窗 73 段／307–364 系 11 窗 41 段／366–438 系 11 窗 30 段／439–475 系 11 窗 70 段；
- 切割仲裁补记（流程总览原件照录）：015 片段 I 补拷 W01；311 片段 B 归 W06；381 片段 A 双投 W28+F31；461 片段 V 经亲审确认为《个人智能创作舱》灵感萌发段、双投 W20+F32；458 片段 F 确认为 W21 实质问答、双投 W21+F32；470 整窗不切单归 F31；473 片段 D/I 归 F32。

第⑥步　质检与统计

- **改名**：第一版长名（改名脚本.py／rename_task2.py：序号_日期_轮数_涉及作品_状态_关键词.json，485/485 成功）；第二版交付短名（rename_short.py，未入档：序号_日期 YYYYMMDD_归属简写_关键词.json，最长 34 字符，485/485 成功）；两版均产出改名对照表；
- **归档**：归档脚本.py（archive_task1.py）——建六个交付文件夹（三个来源包＋30 份过程包＋定稿包＋综合文件夹）；来源三包整体复制并与源目录哈希逐一比对；定

稿入包并分发至对应 W 文件夹；非切割窗按归属二次命名（归属码_窗口 ID_阶段_状态_日期.json，阶段按序位比例 0.25/0.6/0.9 划分初期/中期/末期/最终，唯一窗口为全期）；W12 文件夹置说明签（V18 定稿无过程窗，过程由 W10/W11 前身线承载）；

- **摘要净化**：patch_digests.py——将裁定流程行话逐条改写为真实内容描述（亲审补写，裁定来源仍由”裁定来源”列承载）；
- **统计落盘**：gen_stats.py（11_统计汇总.md）、gen_tables.py（10_全量文件内容总表＋三包分包表）、gen_folder_stats.py/gen_folder_stats2.py（12_三十二文件夹统计汇总，未入档）、窗口预览工具.py（peek.py，判定与抽检期的取样查看工具）；
- **校验**：verify_archive.py（归档完整性：705 个归属-窗校验项零缺失）、verify_cuts3.py（切割守恒：43/44 窗严格满足”片段合计＝原条数＋6×切口数”，432 窗因嵌套提取差 2 条经逐索引核验覆盖完整判定通过；片段副本条数一致性校验）、三包 MD5 全量比对零不一致、过程包整窗副本 556 份抽 55 份（10%）哈希比对零不一致、定稿包 30/30、内容摘要随机 10 窗抽审与原文吻合。

三、用户校准口径（最高优先级，原件照录）

- **R1 求认证＝实质**：单贴作品文案＋求 AI 分析/战略推演/价值评估＝实质·认证；
- **R2 战略分析/模拟/探索＝实质**：“做战略分析以及模拟、探索这些都是实质性创作，是能够进行有效迭代的根本性原因”；
- **R3 贴全文作样品＝仅提及**：为上架/估价/测试而粘贴作品全文，贴的作品不获归属，窗口归 31 文件夹；
- **R4 边界规则**：贴 W01 文本求评估/打磨/上书推广→W01；讨论数据集本身（上架/定价/参赛/合规/检索）→F31；两者皆有→双归属；

- **R5 清单外项目→F32**：绝密基地计划、穿越 3026 年小说大纲、工具问答、纯闲聊。

四、脚本库清单（19 个）

A. 交付脚本存档（13 个，位于 综合文件夹/脚本存档/，历史原件）

#	存档名	工作文件名	功能	关键输出
1	比对脚本.py	compare.py	首轮判定 vs 复检逐窗比对，非法归属词校验	分歧清单（打印）
2	分歧分类脚本.py	classify_diffs.py	分歧分 A/B/C 三类	分歧分类.csv
3	C 类细分脚本.py	classify_c.py	C 类细分 C1/C2/C3/C4	分歧 C 类细分.csv
4	终表汇合脚本.py	merge_final.py	三方汇合生成终版总表（优先级链＋断言校验＋32 类总账）	终版总表_32 类.csv、总匹配表
5	改名脚本.py	rename_task2.py	第一版长名重命名＋改名对照表（幂等）	改名对照表.csv
6	归档脚本.py	archive_task1.py	建交付目录、	六个交付文件

#	存档名	工作文件名	功能	关键输出
			三包复制、定稿入包、非切割窗二次命名、W12 说明签	夹
7	窗口预览工具.py	peek.py	全文渲染件的人类消息取样查看（判定/抽检辅助）	控制台输出
8	patch_digests.py	patch_digests.py	内容摘要亲审补写与行话净化	终版总表（更新理由列）
9	gen_stats.py	gen_stats.py	统计汇总生成（总量/含缺/归属/分布/切割）	11_统计汇总.md
10	gen_tables.py	gen_tables.py	全量内容总表＋三包分包表生成	10_全量文件内容总表等
11	逐轮统计脚本.py	stats_rounds.py	轮次化与逐轮统计	13_逐轮次统计明细.csv
12	verify_archive.py	verify_archive.py	归属-窗配对归档完整性校验	校验报告（705 项零缺失）

#	存档名	工作文件名	功能	关键输出
13	verify_cuts3.py	verify_cuts3.py	切割条数守恒与片段副本一致性校验	守恒校验报告

B. 工作目录补充脚本（6 个，位于 _判定/，未入交付存档，本档案补记）

#	文件名	功能
14	stats_cot.py	思维链含缺与字数实计（思维链统计明细.csv）
15	rename_short.py	第二版交付短名重命名
16	writeback_c34.py	C3/C4 终裁结论与亲审修正写回仲裁 JSON
17	抽检校准.py	55 窗抽检结论落盘＋口径校准写回
18	gen_folder_stats.py	三十二文件夹统计汇总（第一版）
19	gen_folder_stats2.py	三十二文件夹统计汇总（终版）

C. 无独立脚本的环节（如实声明）：容错解析与全文渲染、TF-IDF 初筛打分、切割执行——在当时会话环境中以人机协同方式完成，规则与结果均已留痕（全文渲染件、初判候选列、溯源注释），但无独立脚本文件入档。

五、关键参数实录

参数	取值
归属类别数	32＝N(30 作品类)＋F31＋F32
判定/复检批次	8＋8
切割缓冲	单侧 3 条（每切口重叠 6 条）
碎段并段阈值	<8 条
抽检比例/样本	约 1/9，55 窗，随机种子 20260906
人工仲裁规模	139 窗（C3+C4 共 42 窗逐一亲审＋低置信/待定 24 窗亲审＋A 类校准与采纳），占 28.7%
阶段划分比例	初期<0.25／中期<0.6／末期<0.9／最终;唯一窗口＝全期
终表机器断言	行数=485、ID 1–485 连续、归属词全部合法、无待定/无残留

六、归属体系实例（N=30）

W01–W30 作品类映射（归档脚本 WFOLDER 照录）： W01 思想过程确权方案／W02 循环登高思维／W03 月球火种计划野人文明迭代版／W04 从出租屋失眠到万亿理论小说／W05 AI 等级划分与三级跃迁指南／W06 AI 等级进化工程实施架构书／W07 AI 大模型释压轻量化工程／W08 硬币三问王者之心训练法／W09 智慧文明操作系统六大飞轮／W10 光伏板增量改革自清洁计划 V16／W11 光伏板存量改造自清洁计划 V17／W12 光伏双计划最新版 V18／W13 汽车自定义开源平台架构／W14 赛车产业改革构想／W15 全民文化生态与全球文化输出实施方案／W16 家庭与社会治理全体系闭环草案／W17 超级城

市计划未来都市圈规划构思／W18 数字资源管理中心组织架构／W19 国家数字资源综合管理中心建设提案／W20 个人智能创作舱／W21 共生与数字生命传承体系／W22 全球治理体系／W23 人机两位一体／W24 意识转移载体实现构想／W25 宇宙文明未来推演／W26 宇宙游牧文明推演／W27 时间黑洞宇宙论／W28 黑洞宇宙论 V11／W29 循环时间宇宙论 V12／W30 粒子宇宙论 V13；F31＝过程数据研究/实验/工程/推广/检索收录；F32＝泛化探索/饭聊/清单外项目。

归属分布（《09_审阅说明》终版总账照录，多归属重复计，合计 697）：F31＝126 窗；F32＝46 窗；W01＝257 窗；W03＝61；W10＝28；W05＝24；W02＝20；W28＝15；W27＝14；W23＝13；W06＝12；W04＝10；W08＝9；W07＝7；W24＝7；W26＝7；W15＝5；W25＝5；W29＝4；W09＝3；W16＝3；W18＝3；W21＝3；W22＝3；W13＝2；W14＝2；W17＝2；W30＝2；W11＝2；W19＝1；W20＝1；W12＝0（定稿入包，过程由 W10/W11 承载）。

> 口径说明：归属分布合计 697 与归档校验项 705 的差异，以归档校验脚本（verify_archive.py）实测输出为准——该校验逐”窗口×归属码”核验落盘，是终版校验口径。

七、校验结论实录（2026-09-06 终检）

1. 归档完整性：705 个归属-窗校验项全部落盘，零缺失；仅提及 2 窗（089/090）、无关 6 窗全部正确归 F32；
2. 切割校验：44 窗 214 个唯一片段；43/44 窗严格守恒；432 窗差 2 条经逐索引核验覆盖完整（0–347 连续无缺口），判定通过；片段随机抽验 3 份与源窗逐条吻合；
3. 哈希比对：三包全量 MD5 零不一致；过程包整窗副本 556 份抽 10%（55 份）零不一致；定稿包 30/30；

4. 摘要抽审：随机 10 窗，摘要与原文首中段实际内容全部吻合，表载轮次与实计条数全部一致；
5. 全量统计数字经独立实计复核，与交付统计表零偏差。

八、口径变迁记录：485 → 477（2026 年 10 月）

原因：本数据集原始采集共 485 个会话窗口（DeepSeek 454 窗、Kimi 23 窗、豆包 8 窗）。豆包平台用户协议对输出内容设有商业用途限制（商业禁止协议条款）；因本项目推进数据知识产权登记与合规资产化，为保证登记产权与流通合规，豆包来源 8 窗（窗口 ID：003、020、022、220、273、389、407、412，按改名对照表”所在文件包”列实测）整体剔除，**不进行商用**，不进入登记与流通范围。剔除后的 477 窗为现行唯一对外口径。其中 003、220 两窗原属切割窗，故切割窗由 44 减至 42，唯一片段由 214 减至 198。

指标	485 窗口径（2026-09-06）	477 窗口径（2026-10，现行）
窗口数	485（鲸鱼 454/KM23/豆包 8）	477（鲸鱼 454/KM23）
总轮次	19,165	18,744
三元组	18,143（94.7%）	18,143（96.8%）
两元组	1,022	601
消息条数	39,181	38,336
全量字数	46,733,333 字（含导出附加 578,290 字，旧全量口径）	46,155,043 字（全量文本口径）
归属-窗配对	705	690
切割	44 窗/214 片段	42 窗/198 片段

指标	485 窗口径（2026-09-06）	477 窗口径（2026-10，现行）
过程:定稿	158:1	156:1
单作品最深	8,606 轮（W01）	8,398 轮（W01）

技术说明：豆包窗 421 轮在逐轮统计中字数为 0（导出消息体结构与 text 统计口径不匹配，见第二章第③步），故剔除前后对话口径字数一致；剔除后全部数字已从 477 个原始 JSON 重新实计复核。半结构化原始数据包（477 个 JSON）未压缩约 133MB，ZIP 压缩包 43.9MB，MD5＝082b1acd9bc7662b9aa321c328b0b2bc。

九、已知边界与声明

1. 判定与复检由 AI 代理（判定/复检机器人）执行，**全部分歧与低置信窗口由人工作最终裁决**，抽检样本由人工逐窗核验；机器只负责比对、分类、统计与断言；
2. 脚本中硬编码的绝对路径（/mnt/agents/work/数据整理 等）为历史工作路径，复用脚本时须按规范附录 A 参数区改写；
3. 脚本与规则文档为历史原件，其中窗口数、归属数等均为 485 口径现场值；现行对外口径以第八章 477 窗口径为准；
4. 本档案与《人机协同过程数据治理规范（通用模板）V1.0》配套使用：规范为通用模板（N+2 结构、参数化），本档案为 N=30 的首次完整实施证据。